

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
BACHARELADO EM MATEMÁTICA APLICADA E COMPUTACIONAL
COM HABILITAÇÃO EM MÉTODOS MATEMÁTICOS

**Uma abordagem estocástica para modelos
rápidos-lentos**

Lucas Amaral Taylor

MONOGRAFIA FINAL
MAP 2429 — TRABALHO DE
FORMATURA EM MATEMÁTICA APLICADA

Supervisor: Prof. Dr. Breno Raphaldini Ferreira da Silva

São Paulo
2025

*O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)*

*Na verdade, na verdade vos digo que, se o
grão de trigo, caindo na terra, não morrer,
fica ele só; mas se morrer, dá muito fruto.*

João 12:24

Agradecimentos

Do. Or do not. There is no try.

— Mestre Yoda

Resumo

Lucas Amaral Taylor. **Uma abordagem estocástica para modelos rápidos-lentos.** Monografia (Bacharelado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2025.

escrever

Palavras-chave: Palavra-chave1. Palavra-chave2. Palavra-chave3.

Abstract

Lucas Amaral Taylor. **A stochastic approach to fast-slow models.** Capstone Project Report (Bachelor). Institute of Mathematics and Statistics, University of São Paulo, São Paulo, 2025.

escrever

Keywords: Keyword1. Keyword2. Keyword3.

Lista de figuras

1.1	Diagrama do modelo de água-rasa adaptado	6
1.2	Simulação de 1 dia com $f_1 = 0.1$	11
1.3	Simulação de 50 dias com $f_1 = 0.1$	11
1.4	Simulação de 50 dias com $f_1 = 0.1$	12
1.5	Simulação de 50 dias com $f_1 = 0.1$	13
1.6	Simulação de 50 dias com $f_1 = 0.1$	13
2.1	Comparação entre simulação determinística e estocástica do browniano acoplado.	17
2.2	Comparação entre histogramas das simulações determinística e estocástica do browniano acoplado.	17

Lista de tabelas

Sumário

Introdução	1
1 O modelo de Lorenz 80 determinístico	3
1.1 Introdução	3
1.2 Breves considerações sobre geofísica	3
1.3 Motivação e apresentação do modelo	4
1.4 O modelo de água-rasa	5
1.5 Construção dos modelos	6
1.6 Comparação entre os modelos	9
1.7 Simulações	10
1.7.1 Parâmetros	10
1.7.2 Evolução das variáveis de índice 1	10
1.7.3 Projeções bidimensionais	12
2 Introdução às equações diferenciais estocásticas	15
2.1 Introdução	15
2.2 Noções gerais de estatística	15
2.3 Movimento Browniano	16
2.3.1 Motivação	16
2.3.2 Definição	16
2.3.3 Propriedades	16
2.4 Equações diferenciais estocásticas	16
2.5 Exemplo	16
3 Formalismo Mori-Zwanzig	19
3.1 Introdução	19
3.2 Motivação	19
3.3 Preliminares	20

3.3.1	Convertendo sistemas de EDO não lineares como sistemas de EDPs lineares	20
3.3.2	Notação de semigrupo	20
3.3.3	Polinômios Hermitianos	22
3.4	Mori-Zwanzig	22
3.4.1	Construção	22
3.4.2	Análise termo a termo	24
A	Programas	27
A.1	Código do modelo Lorenz 80 determinístico	27
A.2	Exemplo do capítulo 02	29
B	Considerações matemáticas	33
B.1	Decomposição de Helmholtz	33
Referências		35
Índice remissivo		37

Introdução

Lorem

Capítulo 1

O modelo de Lorenz 80 determinístico

1.1 Introdução

Este capítulo tem como objetivo apresentar o modelo determinístico Lorenz 80. Para isso, começamos, na seção 1.2, com uma introdução aos conceitos básicos de geofísica, a fim de familiarizar o leitor com os fundamentos dessa área. Em seguida, na seção 1.3, contextualizamos o modelo, discutindo os trabalhos que o precederam e as motivações por trás de sua formulação.

Na seção 1.4, introduzimos o modelo de água rasa, que serve de base para o desenvolvimento do Lorenz 80. A construção deste é detalhada na seção 1.5. Por fim, a seção 1.7 traz simulações computacionais realizadas com o modelo, acompanhadas de uma análise gráfica dos resultados.

1.2 Breves considerações sobre geofísica

Nesta seção, reunimos um breve glossário com os principais conceitos de geofísica que servem de base para a compreensão do modelo de Lorenz 80. Todas as definições expostas abaixo estão detalhadas em [VALLIS \(2017\)](#).

- **Convecção.** Convecção é um processo de transferência de calor que ocorre em fluidos, como líquidos e gases. Esse fenômeno envolve o movimento do próprio fluido e a transferência energia térmica de uma região para outra.
- **Parâmetro de Coriolis.** A *força de Coriolis* é uma quasi-força (ou pseudo-força) que surge devido à rotação da Terra. Quando analisamos o movimento de um corpo em um referencial rotativo, esse corpo parece sofrer a ação de uma força que desvia sua trajetória. Esse desvio é quantificado pelo parâmetro de Coriolis, definido pela expressão:

$$f = 2\Omega \sin(\theta)$$

onde Ω representa a velocidade angular de rotação da Terra e θ é a latitude, ou seja, o ângulo entre a posição do ponto e o equador terrestre.

- **Número de Rossby.** O número de Rossby é a razão entre a magnitude da aceleração relativa e a aceleração de Coriolis. É aproximado por:

$$Ro \equiv \frac{U}{fL},$$

onde U é a magnitude aproximada da velocidade horizontal e L é uma escala de comprimento e f é o parâmetro de Coriolis.

- **Equilíbrio hidrostático.** Matematicamente, a equação do equilíbrio hidrostático é dada por:

$$\frac{\partial p}{\partial z} = -\rho_0 g, \quad (1.1)$$

onde: p é a pressão do fluido, z é a coordenada vertical, ρ_0 é a densidade constante do fluido e g é a aceleração da gravidade.

- **Conservação de massa.** Em um escoamento de fluido, a densidade pode variar de acordo com o tempo ou a posição. No entanto, a *quantidade total de massa* do fluido permanece constante. Esse princípio estabelece que a massa não pode ser criada nem perdida durante o movimento.
- **Equações quasi-geostróficas.** As equações quasi-geostróficas são equações amplamente usadas em estudos teóricos da atmosfera e oceano. Elas atendem as seguintes características:

1. O número de Rossby é pequeno;
2. A escala do movimento não é significativamente maior do que a escala de deformação;
3. As variações no parâmetro de Coriolis são pequenas;
4. As escalas de tempo são advectivas, ou seja, $T = L/U$.

- **Condições de Hardley.**

1.3 Motivação e apresentação do modelo

Edward Norton Lorenz (1917-2008) foi um importante matemático e meteorologista responsável pela publicação de vários artigos com desenvolvimento de modelos na área de meteorologia e geofísica.

O mais famoso deles foi o artigo “*Deterministic Nonperiodic Flow*”, publicado em 1963 E. N. LORENZ (1963). Nele, Lorenz desenvolveu um modelo matemático simplificado para a convecção atmosférica, composto por três equações diferenciais ordinárias, expressas

abaixo:

$$\begin{cases} \frac{dx}{dt} = \sigma(y - x) \\ \frac{dy}{dt} = x(\rho - z) - y, \\ \frac{dz}{dt} = xy - \beta z \end{cases} \quad (1.2)$$

onde σ é o *número de Prandtl*, que regula a sensibilidade entre x e y ; ρ é o *número de Rayleigh*, associado à magnitude da convecção; e β está ligado à geometria da célula de convecção, influenciando a relação entre as taxas de x e z .

O modelo acima, conhecido como Lorenz 63, é um sistema determinístico desenvolvido para representar sistemas hidrodinâmicos ideais e dissipativos de força. O Lorenz 63 tornou-se amplamente conhecido por sua alta sensibilidade às condições iniciais — pequenas alterações nas variáveis x_0 , y_0 e z_0 podem levar a trajetórias completamente distintas no espaço de fases. Essa sensibilidade extrema é uma característica caótica do modelo.

Em 1980, Lorenz publica o artigo intitulado “*Attractor Sets and Quasi-Geostrophic Equilibrium*” (Edward N. LORENZ, 1980). Neste artigo, Lorenz apresenta a construção e a simulação de dois modelos distintos: o primeiro, é formado a partir das equações primitivas (PE) com nove EDOs (equações diferenciais ordinárias), derivado das equações de águas rasas com topografia e forçamento, enquanto o segundo é um modelo quasi-geostrófico (QG) com 3 EDOs, obtido ao descartar as variáveis associadas ao escoamento divergente x e seus termos correspondentes. O modelo PE contém tanto ondas gravitacionais rápidas quanto oscilações quasi-geostróficas lentas, enquanto o modelo QG mantém apenas estas últimas, em um quadro simplificado para atmosfera de latitudes médias.

1.4 O modelo de água-rasa

O modelo de água rasa descreve um fluido de densidade constante, em equilíbrio hidrostático, que pode ou não estar em rotação. Nele, a escala horizontal é significativamente maior que a profundidade. Esse fluido possui superfície livre e é limitado pelas bordas (VALLIS, 2017). No caso considerado, adotamos a versão de uma única camada.

Para a construção do modelo de água-rasa, consideramos a equação do equilíbrio hidrostático, expressa em (1.1). A partir das manipulações envolvendo os conceitos de momento e conservação de massa, detalhado em VALLIS (2017), obtemos as equações que descrevem o modelo:

$$\frac{\partial V}{\partial t} + (V \cdot \nabla) V + f \mathbf{k} \times V = -g \nabla \eta \quad (1.3)$$

$$\frac{\partial \eta}{\partial t} + \nabla \cdot (\eta V) = 0 \quad (1.4)$$

Onde:

- t : tempo;
- \mathbf{r} : vetor de posição inicial;

- $V(t)$: Velocidade horizontal;
- $\eta(t)$: altura da superfície;
- \mathbf{k} : vetor da vertical.

1.5 Construção dos modelos

Nesta seção, apresentaremos a construção dos modelos apresentados no artigo [Edward N. LORENZ \(1980\)](#). Como dito anteriormente, o modelo é construído a partir das equações de água-rasa com algumas particularidades descritas a seguir.

Consideremos um fluido homogêneo e incompressível, ou seja, com densidade constante em todo o volume e volume invariável mesmo sob variações de pressão. O escoamento é predominantemente horizontal, descrito por uma velocidade $V(t, \mathbf{r})$ independente da altura, onde \mathbf{r} representa o vetor de posição inicial.

A componente vertical da velocidade é determinada pela continuidade de massa. A superfície livre do fluido está localizada na altura $H + z(t, \mathbf{r})$, onde H representa a profundidade média e a base se apoia sobre uma topografia variável $h(\mathbf{r})$. Temos também que $h(\mathbf{r})$ e $z(t, \mathbf{r})$ possuem média zero.

O sistema está sujeito à rotação planetária, com um parâmetro de Coriolis constante f . Tanto o campo de velocidades V quanto a elevação da superfície z sofrem dissipação difusiva, associada a movimentos de pequena escala: o termo ν representa o coeficiente de difusão viscosa (dissipação de momento) e κ representa o coeficiente de difusão térmica. O modelo também inclui um termo de forçamento externo $F(\mathbf{r})$ e, por fim, adota-se a hipótese de equilíbrio hidrostático.

A partir da descrição acima, podemos construir o seguinte diagrama:

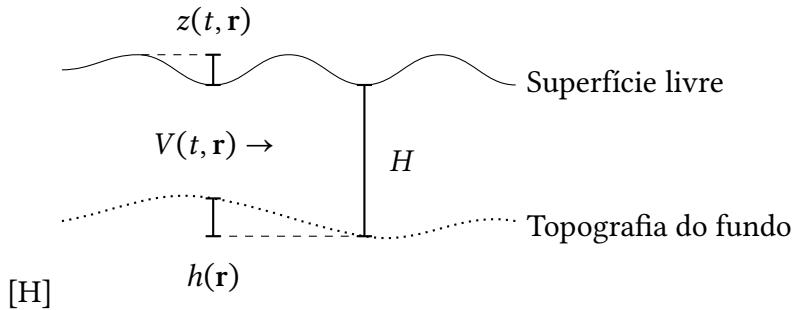


Figura 1.1: Diagrama do modelo de água-rasa adaptado

Além disso, o modelo de água-rasa adaptado é expresso por:

$$\frac{\partial V}{\partial t} = -(V \cdot \nabla)V - f\mathbf{k} \times V - g\nabla z + \nu\nabla^2 V \quad (1.5)$$

$$\frac{\partial z}{\partial t} = -(V \cdot \nabla)(z - h) - (H + z - h)\nabla \cdot V + \kappa\nabla^2 z + F \quad (1.6)$$

Onde:

- H : profundidade média do fluido;
- $h(\mathbf{r})$: variação da superfície topológica;
- $V(t, \mathbf{r})$: Velocidade horizontal;
- $z(t, \mathbf{r})$: altura da superfície;
- F : forças externas;
- κ : coeficiente de difusão viscosa;
- ν : coeficiente de difusão térmica;

Em seguida, aplicamos a *decomposição de Helmholtz*¹ à equação (1.5), escrevendo

$$V = \nabla \chi + \mathbf{k} \times \nabla \psi,$$

onde χ é o potencial de velocidade associado à parte divergente e ψ a função corrente associada à parte rotacional. Dessa forma, $\nabla^2 \chi$ representa a divergência e $\nabla^2 \psi$ a vorticidade. Substituindo essa decomposição obtemos:

$$\begin{aligned} \frac{\partial \nabla^2 \chi}{\partial t} &= -\frac{1}{2} \nabla^2 (\nabla \chi \cdot \nabla \chi) - \nabla \chi \cdot \nabla (\nabla^2 \psi) \times \mathbf{k} + \nabla^2 (\nabla \chi \cdot \nabla \psi \times \mathbf{k}) \\ &\quad + \nabla \cdot (\nabla^2 \psi \nabla \psi) - \frac{1}{2} \nabla^2 (\nabla \psi \cdot \nabla \psi) + \nu \nabla^4 \chi + f \nabla^2 \psi - g \nabla^2 z, \end{aligned} \quad (1.7)$$

$$\frac{\partial \nabla^2 \psi}{\partial t} = -\nabla \cdot (\nabla^2 \psi \nabla \chi) - \nabla \psi \cdot \nabla (\nabla^2 \psi) \times \mathbf{k} - f \nabla^2 \chi + \nu \nabla^4 \psi. \quad (1.8)$$

Analogamente, aplicando (1.6), temos:

$$\frac{\partial z}{\partial t} = -\nabla \cdot [(z - h) \nabla \chi] - \nabla \psi \cdot \nabla (z - h) \times \mathbf{k} - H \nabla^2 \chi + \kappa \nabla^2 z + F. \quad (1.9)$$

Nosso objetivo é reduzir as equações (1.7)–(1.9) a um modelo de baixa ordem. Para isso, introduzimos três vetores adimensionais $\alpha_1, \alpha_2, \alpha_3$ que satisfazem

$$\alpha_1 + \alpha_2 + \alpha_3 = 0,$$

e adotamos as permutações cíclicas

$$(i, j, k) = (1, 2, 3), (2, 3, 1), (3, 1, 2).$$

Definimos então:

$$a_i = \alpha_i \cdot \alpha_i, \quad b_i = \alpha_j \cdot \alpha_k, \quad c = (b_1 b_2 + b_2 b_3 + b_3 b_1)^{1/2}.$$

Lorenz também apresenta uma forma alternativa, equivalente, mais conveniente para

¹ Definição apresentada no apêndice B

a implementação computacional:

$$b_i = \frac{1}{2}(a_i - a_j - a_k), \quad c_i = c.$$

Escolhido um comprimento característico L , construímos três funções ortogonais:

$$\phi_i(\mathbf{r}) = \cos\left(\alpha_i \cdot \frac{\mathbf{r}}{L}\right),$$

para as quais valem, por exemplo:

$$\begin{aligned} L^2 \nabla^2 \phi_i &= -a_i \phi_i, \\ L^2 \nabla \phi_i \cdot \nabla \phi_k &= -\frac{1}{2} b_{ik} \phi_i + \dots, \\ L^2 \nabla \cdot (\phi_j \nabla \phi_k) &= \frac{1}{2} b_{jk} \phi_i + \dots, \\ L^2 \phi_j \cdot \nabla \phi_k \times \mathbf{k} &= -\frac{1}{2} c_{jk} \phi_i + \dots, \end{aligned}$$

onde os termos omitidos são múltiplos de cossenos. Com essas funções, expandimos as variáveis em série e introduzimos escalas adimensionais:

$$\begin{aligned} t &= f^{-1} \tau, \\ \chi &= 2L^2 f^2 \sum_i x_i \phi_i, \\ \psi &= 2L^2 f^2 \sum_i y_i \phi_i, \\ z &= 2L^2 f^2 g^{-1} \sum_i z_i \phi_i, \\ h &= 2L^2 f^2 g^{-1} \sum_i h_i \phi_i, \\ F &= 2L^2 f^2 g^{-1} \sum_i F_i \phi_i. \end{aligned} \tag{1.10}$$

Substituindo as equações de (1.10) em (1.7)–(1.9), e projetando sobre a base $\{\phi_i\}$, obtemos finalmente o modelo PE de baixa ordem, composto de nove equações diferenciais ordinárias:

$$a_i \frac{dx_i}{d\tau} = a_i b_i x_i x_k - c(a_i - a_k) x_i y_k + c(a_i - a_j) y_i x_k - 2c^2 y_i y_k - v_0 a_i^2 x_i + a_i y_i - a_i z_i, \tag{1.11}$$

$$a_i \frac{dy_i}{d\tau} = -a_i b_k x_i y_k - a_i b_i y_i x_k + c(a_k - a_i) y_i y_k - a_i x_i - v_0 a_i^2 y_i, \tag{1.12}$$

$$\frac{dz_i}{d\tau} = -b_k x_i (z_k - h_k) - b_i (z_i - h_i) x_k + c y_i (z_k - h_k) - c(z_i - h_i) y_k + g_0 a_i x_i - \kappa_0 a_i z_i + F_i. \tag{1.13}$$

As variáveis x_i representam os modos divergentes do escoamento, associados às ondas de gravidade; as variáveis y_i correspondem aos modos rotacionais (vorticidade), ligados às oscilações quasi-geostróficas; e as variáveis z_i funcionam como variáveis auxiliares acopladas ao sistema.

Na construção do modelo QG, começamos desprezando todos os termos não lineares, assim como aqueles que envolvem as variáveis x , incluindo a derivada temporal, na equação (1.11). Fazemos o mesmo com os termos não lineares ou topográficos que dependem de x nas equações (1.12) e (1.13). Por fim, eliminamos as variáveis x e z , obtendo ao modelo QG apresentado a seguir:

$$(a_i g_0 + 1) \frac{dy_i}{d\tau} = g_0 c(a_k - a_j)y_j y_k - a_i(a_i g_0 v_0 + \kappa_0)y_i - ch_k y_j + ch_j y_k + F_i, \quad (1.14)$$

ADICIONAR SOBRE O CAPÍTULO 2.7 DO SALMON

1.6 Comparação entre os modelos

É importante destacar que, para apresentação, optei por realizar a comparação entre os modelos tomando apenas a base como critério. Nas seções finais do artigo [Edward N. LORENZ, 1980](#), há uma análise detalhada sobre a estrutura do atrator e sua relação com a variedade invariante, incluindo suas propriedades qualitativas.

Primeiro, consideremos um modelo dissipativo forçado genérico:

$$\frac{dw_i}{dt} = \sum_{j,k}^N a_{ijk} w_j w_k - \sum_j^N b_{ij} w_j + c_i. \quad (1.15)$$

Nele, definimos

$$A = \sum_{i,j,k}^N a_{ijk} w_i w_j w_k, \quad B = \sum_{i,j}^N b_{ij} w_i w_j > 0, \quad C = \sum_i^N c_i w_i, \quad R^2 = \sum_i^N w_i^2.$$

O termo A é um polinômio cúbico que representa as interações não lineares entre as componentes do sistema, B é um polinômio quadrático que representa a dissipação, C é um polinômio linear associado ao forçamento externo e R é a norma euclidiana ao quadrado, representando a energia total. Além disso, definimos A_1 e C_1 como os máximos de A e C , e B_1 como o mínimo de B .

Os modelos analisados em [Edward N. LORENZ, 1980](#) devem satisfazer algumas condições. A primeira é a condição de dissipação:

$$B_1^2 - 4A_1C_1 > 0. \quad (1.16)$$

A segunda é uma restrição sobre os coeficientes do sistema,

$$a_{ijk} = 0 \quad \text{se} \quad j = 1 \quad \text{e} \quad k = i,$$

e, por fim, temos a condição de volume zero: a taxa de variação do volume satisfaz

$$\frac{dV}{dt} = -V \sum_{i=1}^N b_{ii}, \quad (1.17)$$

o que implica que o volume diminui exponencialmente ao longo do tempo devido à dissipação do sistema.

A equação (1.17) mostra que, como B é positivo definido, o volume V tende a zero quando o tempo avança. Isso implica que a dinâmica do sistema se restringe progressivamente a regiões de menor volume no espaço de fase. Qualquer superfície inicial S gera uma sequência S_1, S_2, \dots , cada uma com volume menor que a anterior, até que, no limite, a sucessão de superfícies converge para um subconjunto de dimensão inferior, caracterizando um atrator dissipativo.

Relacionando esse modelo genérico aos modelos construídos, destacam-se dois casos. No modelo QG, a energia total é aproximadamente conservada pelos termos quadráticos, e a dissipação introduzida pelos processos de difusão atua de modo análogo ao termo dissipativo de (1.15), de forma que o atrator possui volume zero. Já no modelo PE, embora a energia total não seja exatamente conservada, se $F_1^2 + F_2^2 + F_3^2$ for suficientemente pequeno, a condição (1.16) é satisfeita. Nesse caso, as trajetórias permanecem limitadas e o atrator também apresenta volume zero.

1.7 Simulações

Nesta seção, expor os resultados gráficos das simulações do Lorenz 80 determinístico com o objetivo de apresentar ao leitor o comportamento do modelo visualmente, bem como exibir características e propriedades do modelo.

Para as simulações utilizamos a linguagem *Python*, em particular, bibliotecas *scipy*, *numpy* e *pandas*. O código utilizado está no apêndice A.

Apresentaremos dois tipos de simulação: a primeira trata-se da evolução das variáveis x_1 , y_1 e z_1 em relação ao tempo e a segunda são as projeções bidimensionais das variáveis y : $y_3 \times y_2$, $y_1 \times y_3$ e $y_1 \times y_2$.

1.7.1 Parâmetros

Os parâmetros fixos nos dois tipos de simulação: $\kappa = \nu = \frac{1}{48}$, $g_0 = 8 \text{ m} \cdot \text{s}^{-2}$, $a_1 = a_2 = 1$, $a_3 = 3$, $h_1 = -1$ e $h_2 = h_3 = f_2 = f_3 = 0$.

O único parâmetro que não será igual nas duas simulações será o valor de f_1 . Nas simulações referentes à evolução das variáveis de índice 1, tomamos $f_1 = 0.1$ e nas projeções bidimensionais, tomamos $f_1 = 0.3027$. A escolha de f_1 é uma escolha sensível que muda totalmente o comportamento do sistema, tanto que a escolha de f_1 no modelo Lorenz 80 é tema de alguns artigos científicos posteriores a Edward N. LORENZ (1980).

1.7.2 Evolução das variáveis de índice 1

Tomamos $f_1 = 0.1$ e as condições iniciais são:

$$x_i = y_i = z_i = 0.1, \quad \forall i \in \{1, 2, 3\}$$

Para tais valores, obtivemos os seguintes resultados:

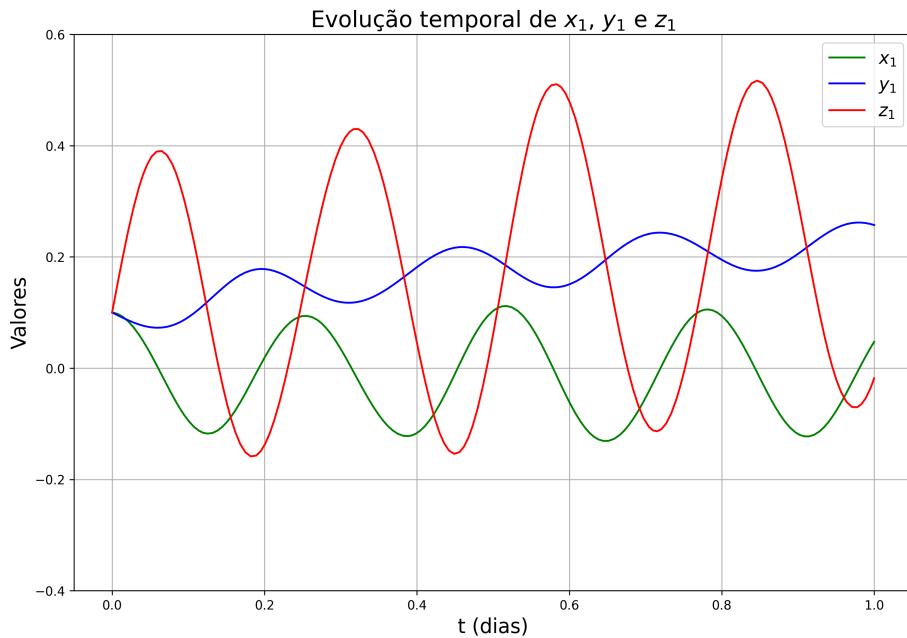


Figura 1.2: Simulação de 1 dia com $f_1 = 0.1$

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nullam posuere elit ut faucibus aliquet. In efficitur neque lectus, vel cursus nisl laoreet sed. Duis tempus ex tortor, consectetur vehicula ex suscipit id. Aliquam hendrerit, odio ut ullamcorper fringilla, purus tellus semper sapien, in aliquet tellus tellus in justo. Aliquam erat volutpat.

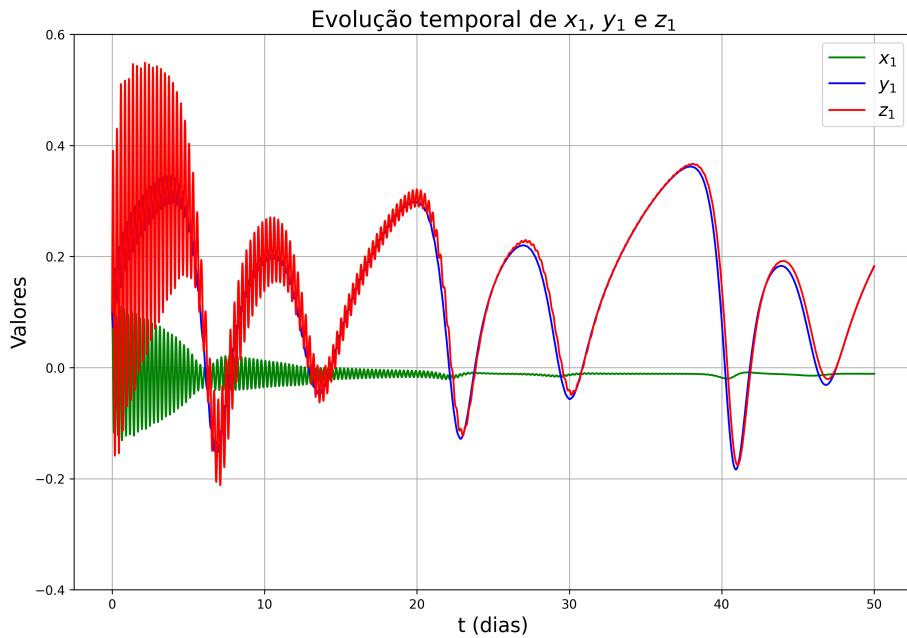


Figura 1.3: Simulação de 50 dias com $f_1 = 0.1$

Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Aenean dignissim mollis augue tristique ornare. Quisque vulputate sapien quis sapien sollicitudin, nec imperdiet lacinia molestie. Vivamus et dui mauris. Sed feugiat augue vitae consequat viverra. Pellentesque volutpat luctus lobortis. Fusce ac pharetra velit. Suspendisse potenti. Etiam in orci non lorem eleifend varius.

1.7.3 Projeções bidimensionais

Para as projeções bidimensionais, utilizamos $f_1 = 0.3027$ e as variáveis iniciais com as condições de Hardley expressas matematicamente abaixo:

$$y_1 = \frac{f_1}{a_1 v_0 \cdot (1 + a_1 g_0)}, \quad x_1 = -v_0 a_1 y_1 \quad \text{e} \quad z_1 = y_1$$

Com pequenas perturbações em y_2 e z_2 :

$$y_2 = -1 \times 10^{-5} \quad \text{e} \quad z_2 = 1 \times 10^{-5},$$

e o restante das variáveis iguais a zero. As simulações correspondem ao período de 400 dias e, foi eliminado os 10% dos dados iniciais, já que estes são uma fase que o sistema ainda está entrando no formado de atrator. Isto posto, conseguimos os seguintes resultados:

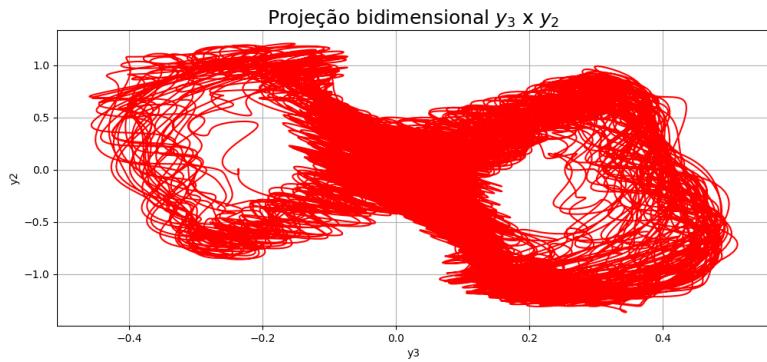


Figura 1.4: Simulação de 50 dias com $f_1 = 0.1$

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nullam posuere elit ut faucibus aliquet. In efficitur neque lectus, vel cursus nisl laoreet sed. Duis tempus ex tortor, consectetur vehicula ex suscipit id. Aliquam hendrerit, odio ut ullamcorper fringilla, purus tellus semper sapien, in aliquet tellus tellus in justo. Aliquam erat volutpat.

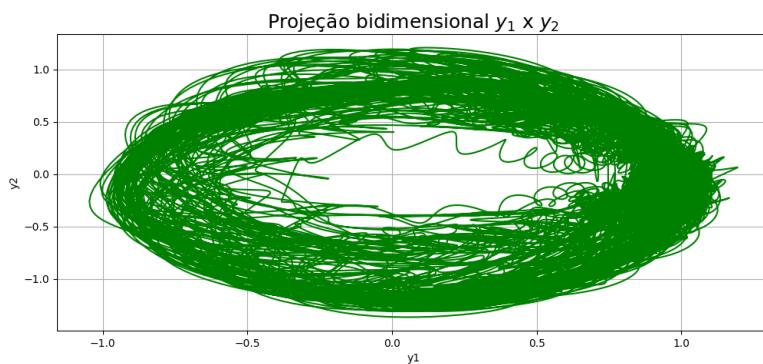


Figura 1.5: Simulação de 50 dias com $f_1 = 0.1$

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nullam posuere elit ut faucibus aliquet. In efficitur neque lectus, vel cursus nisl laoreet sed. Duis tempus ex tortor, consectetur vehicula ex suscipit id. Aliquam hendrerit, odio ut ullamcorper fringilla, purus tellus semper sapien, in aliquet tellus tellus in justo. Aliquam erat volutpat.

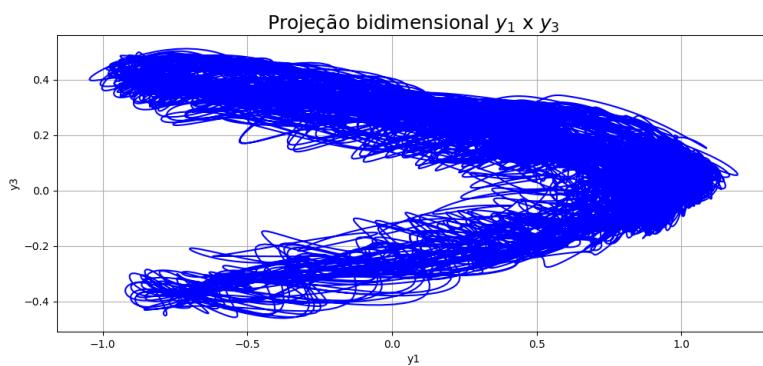


Figura 1.6: Simulação de 50 dias com $f_1 = 0.1$

Capítulo 2

Introdução às equações diferenciais estocásticas

2.1 Introdução

2.2 Noções gerais de estatística

Nesta seção, vamos apresentar as principais definições e teoremas relacionados a probabilidade e estatística que constroem a base necessária para compreensão de equações diferenciais estocásticas. Todos os conceitos apresentados estão detalhados em PAVLIOTIS (2014) e EVANS (2014).

- **Variável aleatória.** Seja $(\Omega, \mathcal{F}, \mathbb{P})$ um espaço de probabilidade e (E, \mathcal{G}) um espaço mensurável. Definimos uma variável aleatória como uma função mensurável da forma

$$X : (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G}).$$

- **Processo Estocástico.** Definimos um processo estocástico como sendo uma coleção de variáveis aleatórias $\{X(t) : t \in T\}$, onde T é um conjunto ordenado.
- **Esperança condicional.**
- **Processos de Markov.**
- **Equações de Champman-Kolmogorov.**
- **Processo de difusão.**
- ***Forward and Backward Kolmogorov Equation***

2.3 Movimento Browniano

2.3.1 Motivação

2.3.2 Definição

2.3.3 Propriedades

Um processo estocástico real, denotado por $W(\cdot)$ é chamado de processo de Wiener quando satisfaz as seguintes propriedades:

1. $W(0) = 0$, quase certamente;
2. Para todo $t \geq s \geq 0$, tem-se que $W(t) - W(s) \sim \text{Normal}(0, t - s)$;
3. $W(\cdot)$ possui incrementos independentes, isto é, para $0 < t_1 < t_2 < \dots < t_n$, as variáveis aleatórias

$W(t_1), W(t_2) - W(t_1), \dots, W(t_n) - W(t_{n-1})$ são independentes.

2.4 Equações diferenciais estocásticas

2.5 Exemplo

A seguir, apresentemos um exemplo retirado de [PAVLIOTIS e STUART \(2008\)](#) de uma aproximação de um sistema determinístico para um sistema estocástico. Tal exemplo é relevante, pois trata-se de uma abordagem simplificada do que vamos realizar com o modelo de Lorenz 80.

O exemplo trata-se de um movimento browniano, assim como apresentado em na seção 2.3.3 acoplado ao sistema Lorenz 63 apresentado em 1.2 a partir das variáveis $y = (y_1, y_2, y_3)^T$. O exemplo em questão é expresso por:

$$\begin{aligned} \frac{dx}{dt} &= x - x^3 + \frac{\lambda}{\varepsilon} y_2, \\ \frac{dy_1}{dt} &= \frac{10}{\varepsilon^2} (y_2 - y_1), \\ \frac{dy_2}{dt} &= \frac{1}{\varepsilon^2} (28y_1 - y_2 - y_1 y_3), \\ \frac{dy_3}{dt} &= \frac{1}{\varepsilon^2} (y_1 y_2 - \frac{8}{3} y_3). \end{aligned} \tag{2.1}$$

EXEMPLIFICAR POR QUE PODEMOS APROXIMAR

Podemos aproximar o modelo para sua versão estocástica forma de Itô:

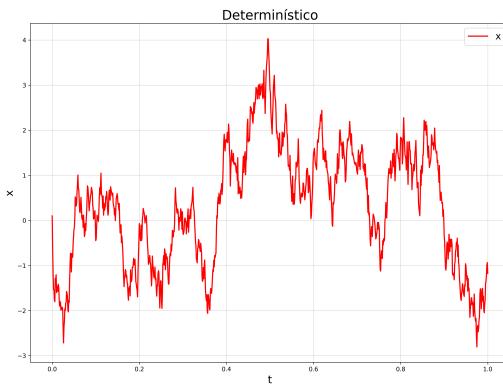
$$\frac{dX}{dt} = X - X^3 + \sigma \frac{dW}{dt}, \tag{2.2}$$

Onde σ é expresso por:

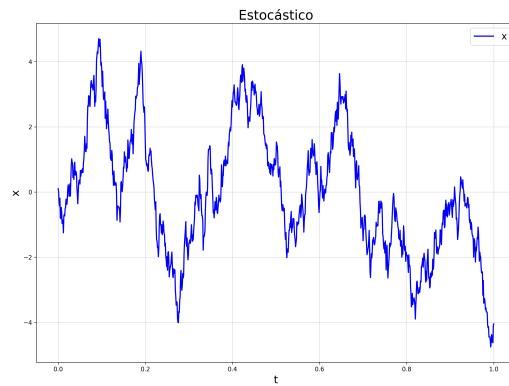
$$\sigma^2 = 2\lambda^2 \int_0^\infty \frac{1}{T} \left(\lim_{T \rightarrow \infty} \int_0^T \psi^s(y) \psi^{t+s}(y) ds \right) dt. \quad (2.3)$$

A partir das equações apresentadas, podemos realizar simulações computacionais. Novamente, as simulações foram realizadas com o uso da biblioteca *SciML* ([RACKAUCKAS e NIE, 2017](#)) e os programas que geraram os dados estão no apêndice A.

VER O NEGÓCIO DA SEED

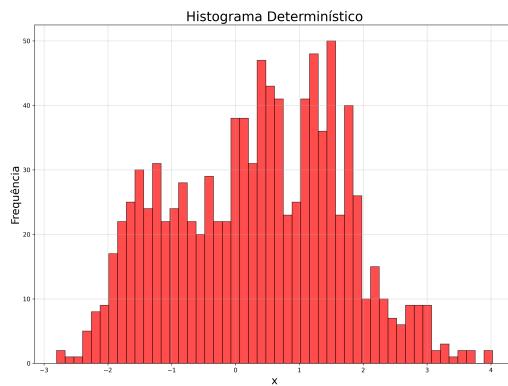


(a) Browniano acoplado determinístico.

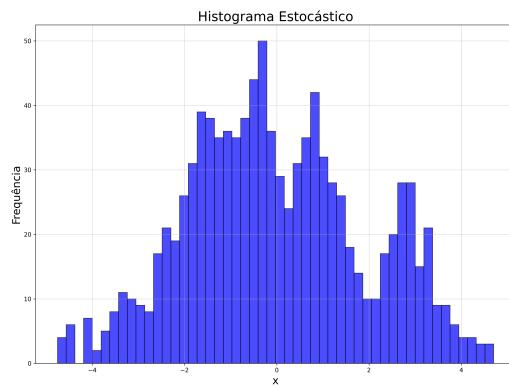


(b) Browniano acoplado estocástico.

Figura 2.1: Comparação entre simulação determinística e estocástica do browniano acoplado.



(a) Histograma do browniano acoplado determinístico.



(b) Histograma do browniano acoplado estocástico.

Figura 2.2: Comparação entre histogramas das simulações determinística e estocástica do browniano acoplado.

Capítulo 3

Formalismo Mori-Zwanzig

3.1 Introdução

Neste capítulo, apresentaremos o formalismo de Mori-Zwanzig (MZ). Para isso iniciamos com uma breve discussão sobre o formalismo MZ e sua importância no contexto deste trabalho (seção 3.2). Em seguida, revisamos conceitos matemáticos fundamentais para sua formulação, como o operador de Liouville, a notação de semigrupos e os polinômios hermitianos (seção 3.3). Por fim, na seção 3.4, desenvolvemos o formalismo passo a passo, analisando cada termo de forma detalhada.

Como referência utilizamos o trabalho do matemático Alexandre J. Chorin: **CHORIN, HALD e KUPFERMAN (2000)**, **CHORIN, HALD e KUPFERMAN (2002)** e, principalmente, **CHORIN e HALD (2013)**.

3.2 Motivação

O método de Mori-Zwanzig, desenvolvido por Robert Walter Zwanzig e Hajime Mori na segunda metade do século XX, é utilizado em sistemas hamiltonianos. Esse método consiste em classificar as variáveis do sistema em duas categorias: “resolvidas” e “não resolvidas”. As variáveis resolvidas são aquelas cujos comportamentos e valores são bem conhecidos, enquanto as não resolvidas são aquelas para as quais não se possui informações diretas. Para substituir essas variáveis não resolvidas, o método introduz termos estocásticos, denominados ruídos (*noise*), além de um termo de amortecimento (*damping*), também conhecido como termo de memória (*memory term*). Essa abordagem permite que o comportamento do sistema de interesse seja preservado de maneira adequada, mesmo sem conhecer completamente as variáveis não resolvidas.

O principal objetivo do artigo de **CHEKROUN et al. (2021)** é simplificar o modelo de Lorenz 80, preservando seu comportamento. Para isso, utilizaremos o método de Mori-Zwanzig, que é uma abordagem física-estatística aplicável em sistemas como o L80. Dada a relevância deste método para o trabalho de **CHEKROUN et al. (2021)**, optamos por incluir uma introdução ao formalismo de Mori-Zwanzig, a fim de proporcionar uma melhor

compreensão de sua aplicação no contexto do modelo de Lorenz 80 e permitir uma base teórica sólida para eventuais explorações.

3.3 Preliminares

3.3.1 Convertendo sistemas de EDO não lineares como sistemas de EDPs lineares

Considere o sistema de equações diferenciais ordinárias (EDO) dado por:

$$\frac{d}{dt}\varphi(x, t) = R(\varphi(x, t)), \quad \varphi(x, 0) = x, \quad (3.1)$$

onde R é uma função não linear, φ é uma função dependente do tempo, e R , φ e x podem assumir dimensões infinitas, sendo formados pelos vetores R_i , φ_i e x_i , respectivamente.

A partir disso, podemos definir o *Operador de Liouville* associado à equação (3.1) como:

$$L = \sum_i R_i(x) \frac{\partial}{\partial x_i} \quad (3.2)$$

Utilizando o *Operador de Liouville*, podemos transformar o sistema de EDOs não lineares em um sistema de equações diferenciais parciais (EDPs) lineares da forma:

$$u_t = Lu, \quad u(x, 0) = g(x) \quad (3.3)$$

A solução desse sistema existe, é única, e é dada por:

$$u(x, t) = g(\varphi(x, t)) \quad (3.4)$$

Portanto, temos que a equação (3.3) é bem definida.¹

3.3.2 Notação de semigrupo

Tomemos X um conjunto não vazio, dotado de uma operação binária $*$, ou seja, $X \times X \rightarrow X$, que satisfaz a propriedade de associatividade:

$$(a * b) * c = a * (b * c), \quad \forall a, b, c \in X.$$

A notação de semigrupo oferece uma forma compacta e eficiente de representar soluções para equações diferenciais, particularmente as parciais ou de evolução.

Considere o operador Δ definido por:

$$\Delta\psi = \psi_{xx}, \quad \text{onde } \psi \text{ é uma função suave.}$$

¹ Detalhes da demonstração podem ser encontrados em CHORIN e HALD (2013, p. 181-182)

Agora, considere a equação diferencial:

$$\frac{dv}{dt} - kv = 0, \quad v(0) = v_0,$$

cuja solução é bem conhecida: $v(t) = v_0 e^{kt}$.

De forma análoga, considere a equação do calor:

$$v_t - \frac{1}{2}\Delta v = 0, \quad v(x, 0) = \varphi(x),$$

onde v_t é a derivada de v em relação ao tempo e $\varphi(x)$ é a condição inicial. Em vez de resolver diretamente, expressamos a solução utilizando a notação de semigrupo:

$$v(t) = e^{\frac{1}{2}t\Delta} \varphi.$$

Aqui, $E^{\frac{1}{2}t\Delta}$ é um operador semigrupo gerado pela operação de difusão (pelo operador Δ). Ele é aplicado à condição inicial $\varphi(x)$, e a solução $v(t)$ descreve a evolução temporal de $v(x, t)$ ao longo do tempo t . Essa notação permite representar soluções de equações diferenciais de maneira compacta, explorando a estrutura associativa da operação de semigrupo. Especificamente, ela satisfaz a propriedade de composição:

$$e^{\frac{1}{2}(t+s)\Delta} = e^{\frac{1}{2}t\Delta} e^{\frac{1}{2}s\Delta}.$$

Dada a notação de semigrupo apresentada anteriormente, aplicamos esta notação à equação (3.4):

$$e^{tL} g(x) = g(\varphi(x, t)) \tag{3.5}$$

Note que $E^{tL}x$ não representa uma avaliação direta de E^{tL} , mas sim a ação do operador E^{tL} sobre o vetor formado pelos componentes x_i . Além disso, a função g comuta com a variação temporal das condições iniciais de x_i .

Vale destacar que g é uma função independente do tempo em relação às variáveis que descrevem o sistema físico, e sua variação ocorre exclusivamente devido à mudança dessas variáveis ao longo do tempo. Assim, a equação (3.3) pode ser expressa como:

$$Le^{tL} = e^{tL}L \tag{3.6}$$

Essa mesma relação se aplica a matrizes: sejam A e B duas matrizes, então a seguinte identidade é válida:

$$\exp(t(A + B)) = \exp(tA) + \int_0^t \exp((t-s)(A + B)) B \exp(sA) ds \tag{3.7}$$

Esta equação, conhecida como *Fórmula de Duhamel* ou *fórmula de Dyson*, é bem definida.

3.3.3 Polinômios Hermitianos

Primeiramente, definimos o produto interno como:

$$\langle u, v \rangle = \int_{-\infty}^{+\infty} \frac{e^{-x^2/2}}{\sqrt{2\pi}} u(x)v(x) dx \quad (3.8)$$

Os polinômios $p_n(x)$ e $p_m(x)$ são ortonormais em relação a esse produto interno (3.8) quando satisfazem a seguinte condição:

$$\langle p_n, p_m \rangle = \int_{-\infty}^{\infty} e^{-x^2/2} p_n(x)p_m(x) dx = \delta_{nm},$$

em que δ_{nm} é o delta de Kronecker, que apresenta as propriedades:

1. **Ortogonalidade:** Para $n \neq m$, os polinômios são ortogonais, ou seja, o produto interno entre eles é nulo:

$$\langle p_n, p_m \rangle = 0 \quad \text{quando} \quad n \neq m$$

2. **Normalização:** Para $n = m$, os polinômios são normalizados, de modo que o produto interno é igual a 1:

$$\langle p_n, p_n \rangle = 1$$

No caso n -dimensional, o produto interno se generaliza para:

$$\langle u, v \rangle = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} (2\pi)^{-n/2} \exp\left(-\sum_{i=1}^n \frac{x_i^2}{2}\right) u(x)v(x) dx_1 \dots dx_n$$

De forma mais geral, se $H(q, p)$ é um Hamiltoniano, é possível definir uma família de polinômios nas variáveis q e p que sejam ortonormais com respeito à densidade canônica $Z^{-1}e^{-H/T}$. Os polinômios que satisfazem essa condição ainda são chamados de *polinômios hermitianos*.

Por fim, para o formalismo de Mori-Zwanzig, consideraremos um espaço n -dimensional Γ com uma densidade de probabilidade dada. Dividiremos as coordenadas em dois tipos: \hat{x} e \tilde{x} . Seja g uma função de x ; então $\mathbb{P}g = \mathbb{E}[g | \hat{x}]$ é uma projeção ortogonal sobre o subespaço das funções de \hat{x} . Temos que essa projeção gera um subespaço de polinômios hermitianos que são funções de \hat{x} e projetando sobre esses polinômios.

3.4 Mori-Zwanzig

3.4.1 Construção

Tomemos novamente o sistema (3.1), reproduzido abaixo:

$$\frac{d}{dt} \varphi(x, t) = R(\varphi(x, t)), \quad \varphi(x, 0) = x,$$

Lembremos que a equação é composta por componentes de dimensão n . Dentre essas n componentes, definimos as primeiras m componentes de φ , com $m < n$, como as variáveis de interesse. Em seguida, classificamos $\hat{\varphi}$ como as variáveis “resolvidas” e $\tilde{\varphi}$ como as variáveis “não resolvidas”:

$$\varphi = (\hat{\varphi}, \tilde{\varphi}), \quad \hat{\varphi} = (\varphi_1, \dots, \varphi_m), \quad \tilde{\varphi} = (\varphi_{m+1}, \dots, \varphi_n)$$

O mesmo vale para x e R : $x = (\hat{x}, \tilde{x})$ e $R = (\hat{R}, \tilde{R})$. A partir das variáveis resolvidas, buscamos criar previsões para o modelo de interesse, utilizando as soluções de uma parte da equação.

Com base no *Operador de Liouville* e na *notação de semigrupo*, podemos reescrever as componentes de $\hat{\varphi}$ como²:

$$\hat{\varphi}_j(x, t) = e^{tL}x_j, \quad 1 \leq j \leq m$$

Ainda na notação de semigrupo, a equação dessas componentes é dada por:

$$\frac{\partial}{\partial t} e^{tL}x_j = L e^{tL}x_j = e^{tL}Lx \tag{3.9}$$

A partir da *projeção ortogonal* introduzida na seção anterior, definimos \mathbb{P} como a projeção dada por: $\mathbb{P}g(x) = \mathbb{E}[g|\hat{x}]$. Assumimos que, no instante $t = 0$, conhecemos a densidade conjunta de todas as variáveis x , mas apenas os dados iniciais \hat{x} são conhecidos. A densidade das variáveis em \tilde{x} é, então, a densidade conjunta de todas as variáveis x com \hat{x} fixado. Assim, \mathbb{P} é uma projeção sobre um espaço de funções com variáveis fixas e, portanto, independente do tempo.

As projeções $\mathbb{P}\hat{\varphi}(t) = \mathbb{E}[\hat{\varphi}(t)|\hat{x}]$ são de nosso maior interesse, pois estimam o comportamento do sistema a partir de um conjunto reduzido de variáveis.

Definindo $\mathbb{Q} = I - \mathbb{P}$ e considerando que as seguintes propriedades são válidas para quaisquer projeções ortogonais:

1. $\mathbb{P}^2 = \mathbb{P}$;
2. $\mathbb{Q}^2 = \mathbb{Q}$;
3. $\mathbb{P}\mathbb{Q} = 0$.

Podemos reescrever a equação (3.9) como:

$$\frac{\partial}{\partial t} e^{tL}x_j = e^{tL}\mathbb{P}Lx_j + e^{tL}\mathbb{Q}Lx_j \tag{3.10}$$

Utilizando agora a *fórmula de Dyson*, com $A = \mathbb{Q}L$ e $B = \mathbb{Q}L$, obtemos:

$$e^{tL} = e^{t\mathbb{Q}L} + \int_0^t e^{(t-s)L}\mathbb{P}Le^{s\mathbb{Q}L} ds \tag{3.11}$$

² Note que cada componente depende de **todos** os valores de x . Portanto, se \tilde{x} for aleatório, então $\hat{\varphi}$ também será.

Pela linearidade da equação de Liouville e a partir das equações (3.10) e (3.11), obtemos:

$$\frac{\partial}{\partial t} e^{tL} x_j = e^{tL} \mathbb{P} L x_j + e^{tQ^L} Q L x_j + \int_0^t e^{(t-s)L} \mathbb{P} L e^{sQ^L} Q L x_j ds \quad (3.12)$$

A equação acima expressa a *equação de Mori-Zwanzig*.

3.4.2 Análise termo a termo

O primeiro termo é dado por:

$$e^{tL} \mathbb{P} L x_j \quad (3.13)$$

Observe que:

$$L x_j = \sum_i R_i \left(\frac{\partial}{\partial x_i} \right) x_j = R_j(x)$$

Portanto,

$$\mathbb{P} L x_j = \mathbb{E}[R_j(x) | \hat{x}] \quad \text{Note que esta é uma função exclusivamente de } \hat{x}.$$

Com isso, podemos concluir que:

$$e^{tL} \mathbb{P} L x_j = \bar{R}_j(\hat{\phi}(x, t))$$

Mais do que isso: o primeiro termo representa a dinâmica própria do sistema nas variáveis resolvidas. Além disso, trata-se de um termo markoviano, pois depende apenas do estado atual do sistema no tempo t .

Para o segundo termo, definimos:

$$w_j = e^{tQ^L} Q L x_j$$

Por definição, temos:

$$\frac{\partial}{\partial t} w_j(x, t) = Q L w_j(x, t), \quad (3.14)$$

$$w_j(x, 0) = Q L x_j = (I - \mathbb{P}) R_j(x) = R_j(x) - \mathbb{E}[R_j | \hat{x}]. \quad (3.15)$$

Note que $w_j(x, 0) = Q L x_j = R_j(x) - \mathbb{E}[R_j(x) | \hat{x}]$ representa a *parte flutuante* da variável $R_j(x)$, ou seja, o componente imprevisível dado \hat{x} . Essa parte evolui de acordo com as *dinâmicas ortogonais*, de modo que $\mathbb{P} w_j(x, t) = 0$ para todo t , mantendo o termo como um ruído puramente não resolvido ao longo do tempo.

Mais especificamente, o subespaço do ruído (*noise subspace*) é formado pelas componentes das funções que são ortogonais às funções de \hat{x} , geralmente, isso corresponde

a termos que dependem de \tilde{x} .

O terceiro termo, dado por:

$$\int_0^t e^{(t-s)L} \mathbb{P} L e^{sQL} Q L x_j$$

é classificado como o termo de memória (*memory term*), já que este envolve a integração de quantidades que dependem de estados anteriores ao atual.

Tomemos que \mathbb{P} seja projetado na extensão dos polinômios hermitianos $H - 1, H_2, \dots$ com argumentos em \hat{x} . Assim, para dada função ψ , temos que: $\mathbb{P}\psi = \sum(\psi, H_k)H_k$, assim, temos:

$$\begin{aligned} \mathbb{P} L e^{sQL} Q L x_j &= \mathbb{P} L (\mathbb{P} + Q) e^{sQL} Q L x_j \\ &= \mathbb{P} L Q e^{sQL} Q L x_j \\ &= \sum_k \langle L Q e^{sQL} Q L x_j, H_k(\hat{x}) \rangle H_k(\hat{x}). \end{aligned}$$

O produto interno é definido como um valor esperado com respeito à densidade de probabilidade inicial. Vamos assumir que L é antissimétrico, ou seja, $(u, Lv) = -(Lu, v)$, então:

$$\begin{aligned} \langle L Q e^{sQL} Q L x_j, H_k(\hat{x}) \rangle &= -(Q e^{sQL} Q L x_j, LH_k) \\ &= -(e^{sQL} Q L x_j, Q L H_k). \end{aligned}$$

Tanto $Q L x_j$ quanto $Q L H_k$ estão no subespaço de ruído, e $\mathbb{E}^{sQL} Q L x_j$ é uma solução no tempo s da equação de dinâmica ortogonal com dados no subespaço de ruído; $P L e^{sQL} Q L x_j$ é então uma **soma de covariâncias temporais de ruídos**.

Apêndice A

Programas

A.1 Código do modelo Lorenz 80 determinístico

```

1 import numpy as np
2 from scipy.integrate import solve_ivp
3 import pandas as pd
4 from pathlib import Path
5
6 a = [1, 1, 3]
7 b = [
8     0.5 * (a[0] - a[1] - a[2]),
9     0.5 * (a[1] - a[2] - a[0]),
10    0.5 * (a[2] - a[0] - a[1]),
11 ]
12 c = np.sqrt(b[0]*b[1] + b[1]*b[2] + b[2]*b[0])
13
14 h = [-1, 0, 0]
15 f = [0.1, 0, 0]
16 g_0 = 8
17 kappa_0 = 1 / 48
18 nu_0 = kappa_0
19
20 def pe_model(t, u):
21     x = u[0:3]
22     y = u[3:6]
23     z = u[6:9]
24     dx = np.zeros(3)
25     dy = np.zeros(3)
26     dz = np.zeros(3)
27     for i in range(3):
28         j = (i + 1) % 3
29         k = (i + 2) % 3
30         dx[i] = (
31             a[i] * b[i] * x[j] * x[k]

```

```

32             - c * (a[i] - a[k]) * x[j] * y[k]
33             + c * (a[i] - a[j]) * y[j] * x[k]
34             - 2 * c**2 * y[j] * y[k]
35             - nu_0 * (a[i]**2) * x[i]
36             + a[i] * y[i]
37             - a[i] * z[i]
38         ) / a[i]
39         dy[i] = (
40             -a[k] * b[k] * x[j] * y[k]
41             - a[j] * b[j] * y[j] * x[k]
42             + c * (a[k] - a[j]) * y[j] * y[k]
43             - a[i] * x[i]
44             - nu_0 * (a[i]**2) * y[i]
45         ) / a[i]
46         dz[i] = (
47             -b[k] * x[j] * (z[k] - h[k])
48             - b[j] * (z[j] - h[j]) * x[k]
49             + c * y[j] * (z[k] - h[k])
50             - c * (z[j] - h[j]) * y[k]
51             + g_0 * a[i] * x[i]
52             - kappa_0 * a[i] * z[i]
53             + f[i]
54         )
55     return np.concatenate([dx, dy, dz])
56
57 def simulate(x0, y0, z0, days):
58     initial_u = np.concatenate([x0, y0, z0])
59     t_final = days * 8
60     t_span = (0, t_final)
61     sol = solve_ivp(pe_model, t_span, initial_u, method="RK45", atol=1
62                     e-8, rtol=1e-6)
63     return sol.t / 8, sol.y[:3].T, sol.y[3:6].T, sol.y[6:].T
64
65 days = 8
66 """
67 # HARDLEY
68 y1 = f[0]/(a[0]*nu_0*(1+a[0]*g_0))
69 x1 = -nu_0*a[0]*y1
70 z1 = y1
71
72
73 x0 = [x1, 0, 0]
74 y0 = [y1, -(10 ** (-5)), 0]
75 z0 = [z1, 10 ** (-5), 0]
76 """
77
78 # DEFAULT
79

```

A.2 | EXEMPLO DO CAPÍTULO 02

```

80 x0 = [0.1,0.1,0.1]
81 y0 = [0.1,0.1,0.1]
82 z0 = [0.1,0.1,0.1]
83 t, x, y, z = simulate(x0, y0, z0, days)
84
85 x = np.asarray(x)
86 y = np.asarray(y)
87 z = np.asarray(z)
88 t = np.squeeze(np.asarray(t))
89
90 df = pd.DataFrame(
91     {
92         "time": t,
93         "x1": x[:, 0],
94         "x2": x[:, 1],
95         "x3": x[:, 2],
96         "y1": y[:, 0],
97         "y2": y[:, 1],
98         "y3": y[:, 2],
99         "z1": z[:, 0],
100        "z2": z[:, 1],
101        "z3": z[:, 2],
102    }
103 )
104
105 BASE = Path(__file__).resolve().parent
106 DATADIR = BASE / "data"
107 DATADIR.mkdir(parents=True, exist_ok=True)
108 out_file = DATADIR / "python01.csv"
109 df.to_csv(out_file, index=False)
110
111 print(f"CSV salvo em: {out_file}")

```

A.2 Exemplo do capítulo 02

```

1 using DifferentialEquations, ModelingToolkit, Plots, BenchmarkTools,
2           CSV, DataFrames
3
4 @independent_variables t
5 @variables x(t)=0.1 y1(t)=0.01 y2(t)=0.01 y3(t)=0.01
6 @parameters ε=0.01 λ=1.0
7 D = Differential(t)
8
9 eqs = [
10   D(x) ~ x - x^3 + (λ/ε) * y2,
11   D(y1) ~ (10 / ε^2) * (y2 - y1),
12   D(y2) ~ (1 / ε^2) * (28*y1 - y2 - y1*y3),
13   D(y3) ~ (1 / ε^2) * (y1*y2 - (8/3)*y3)

```

```

13 ]
14
15 @mtkbuild sys = ODESystem(eqs, t)
16
17 tspan = (0.0, 1.0)
18 prob = ODEProblem(sys, [], tspan)
19 solucao_deterministico = solve(prob, Tsit5(), reltol=1e-6, abstol=1e
    -7, saveat=1e-3)
20
21 x_vals = solucao_deterministico[x]
22 y2_vals = solucao_deterministico[y2]
23
24 df = DataFrame(t = solucao_deterministico.t, y2 = y2_vals, x = x_vals)
25 cd(@__DIR__)
26 CSV.write("data/deterministico.csv", df)

```

Programa A.1: Modelo determinístico browniano acoplado

```

1 using DataFrames, Plots, CSV, Statistics, StatsBase, DSP
2
3 cd(@__DIR__)
4 df = CSV.read("data/deterministico.csv", DataFrame)
5
6 y2_vals = df[:, 2]
7 t_vals = df[:, 1]
8 Δt = 1e-3
9
10 y2_centered = y2_vals .- mean(y2_vals)
11
12 acor = xcorr(y2_centered; scaling = :coeff)
13 n = length(y2_centered)
14 acor_pos = acor[n:end] # lags ≥ 0
15
16 λ = 1.0
17
18 σ² = 2 * λ² * sum(acor_pos) * Δt
19 σ = sqrt(σ²)
20
21 println(σ)

```

Programa A.2: Cálculo do sigma

```

1 using DifferentialEquations, Plots
2
3 sigma = 8.880502080440465
4 x₀ = 0.1
5 tspan = (0.0, 1.0)
6
7 f1(X, p, t) = X - X^3
8 f2(X, p, t) = p

```

```
9
10 W = WienerProcess(0.0, 0.0)
11 prob = SDEProblem(f1, f2, x0, tspan, sigma; noise = W)
12 solucao_estocastico = solve(prob, EM(), dt = 1e-3)
13
14 df = DataFrame(t = solucao_estocastico.t, x = solucao_estocastico.u)
15 cd(@__DIR__)
16 CSV.write("data/estocastico.csv", df)
```

Programa A.3: *Modelo estocástico browniano acoplado*

Apêndice B

Considerações matemáticas

B.1 Decomposição de Helmholtz

Referências

- [CHEKROUN *et al.* 2021] Mickaël D. CHEKROUN, Honghu LIU e James C. McWILLIAMS. “Stochastic rectification of fast oscillations on slow manifold closures”. *Proceedings of the National Academy of Sciences* 118.48 (nov. de 2021). ISSN: 1091-6490. DOI: [10.1073/pnas.2113650118](https://doi.org/10.1073/pnas.2113650118). URL: <http://dx.doi.org/10.1073/pnas.2113650118> (citado na pg. 19).
- [CHORIN e HALD 2013] Alexandre J. CHORIN e Ole H. HALD. *Stochastic Tools in Mathematics and Science*. Springer New York, 2013. ISBN: 9781461469803. DOI: [10.1007/978-1-4614-6980-3](https://doi.org/10.1007/978-1-4614-6980-3) (citado nas pgs. 19, 20).
- [CHORIN, HALD e KUPFERMAN 2000] Alexandre J. CHORIN, Ole H. HALD e Raz KUPFERMAN. “Optimal prediction and the mori-zwanig representation of irreversible processes”. *Proceedings of the National Academy of Sciences* 97.7 (2000), pp. 2968–2973. DOI: [10.1073/pnas.97.7.2968](https://doi.org/10.1073/pnas.97.7.2968) (citado na pg. 19).
- [CHORIN, HALD e KUPFERMAN 2002] Alexandre J. CHORIN, Ole H. HALD e Raz KUPFERMAN. “Optimal prediction with memory”. *Physica D: Nonlinear Phenomena* 166.3 (2002), pp. 239–257. ISSN: 0167-2789. DOI: [10.1016/S0167-2789\(02\)00446-3](https://doi.org/10.1016/S0167-2789(02)00446-3) (citado na pg. 19).
- [EVANS 2014] Lawrence C. EVANS. *An Introduction to Stochastic Differential Equations*. Providence, RI: American Mathematical Society, jan. de 2014 (citado na pg. 15).
- [E. N. LORENZ 1963] E. N. LORENZ. “Deterministic nonperiodic flow”. *Journal of the Atmospheric Sciences* 20.2 (1963), pp. 130–141. DOI: [10.1175/1520-0469\(1963\)020<0130:DNF>2.0.CO;2](https://doi.org/10.1175/1520-0469(1963)020<0130:DNF>2.0.CO;2) (citado na pg. 4).
- [Edward N. LORENZ 1980] Edward N. LORENZ. “Attractor sets and quasi-geostrophic equilibrium”. *Journal of the Atmospheric Sciences* 37.8 (ago. de 1980), pp. 1685–1699. ISSN: 1520-0469. DOI: [10.1175/1520-0469\(1980\)037<1685:asaqge>2.0.co;2](https://doi.org/10.1175/1520-0469(1980)037<1685:asaqge>2.0.co;2) (citado nas pgs. 5, 6, 9, 10).
- [PAVLIOTIS 2014] Grigorios A. PAVLIOTIS. *Stochastic Processes and Applications: Diffusion Processes, the Fokker-Planck and Langevin Equations*. Springer New York, 2014. ISBN: 9781493913237. DOI: [10.1007/978-1-4939-1323-7](https://doi.org/10.1007/978-1-4939-1323-7) (citado na pg. 15).

- [PAVLIOTIS e STUART 2008] Grigoris A. PAVLIOTIS e Andrew STUART. *Multiscale Methods: Averaging and Homogenization*. Springer New York, 2008. ISBN: 9780387738291. doi: [10.1007/978-0-387-73829-1](https://doi.org/10.1007/978-0-387-73829-1) (citado na pg. 16).
- [RACKAUCKAS e NIE 2017] Christopher RACKAUCKAS e Qing NIE. “DifferentialEquations.jl – a performant and feature-rich ecosystem for solving differential equations in Julia”. *Journal of Open Research Software* 5.1 (2017) (citado na pg. 17).
- [VALLIS 2017] Geoffrey K. VALLIS. *Atmospheric and Oceanic Fluid Dynamics: Fundamentals and Large-Scale Circulation*. Cambridge University Press, jun. de 2017. ISBN: 9781107588417. doi: [10.1017/9781107588417](https://doi.org/10.1017/9781107588417) (citado nas pgs. 3, 5).

Índice remissivo

Captions, *veja* Legendas
Código-fonte, *veja* Floats

Equações, *veja* Modo matemático

Figuras, *veja* Floats

Floats

Algoritmo, *veja* Floats, ordem

Fórmulas, *veja* Modo matemático

Inglês, *veja* Língua estrangeira

Palavras estrangeiras, *veja* Língua estrangeira

Rodapé, notas, *veja* Notas de rodapé

Subcaptions, *veja* Subfiguras
Sublegendas, *veja* Subfiguras

Tabelas, *veja* Floats

Versão corrigida, *veja* Tese/Dissertação,
versões

Versão original, *veja* Tese/Dissertação,
versões